

$$M \quad \begin{array}{|c|} \hline U_0 \\ \hline u_0 = \phi_0(p) \end{array} \quad \begin{array}{|c|} \hline U_1 \\ \hline u_1 = \phi_1(p) \end{array} \quad \begin{array}{|c|} \hline U_2 \\ \hline u_2 = \phi_2(p) \end{array} \quad \begin{array}{l} (U_0, \phi_0) \text{ チャート0} \\ (U_1, \phi_1) \text{ チャート1} \\ (U_2, \phi_2) \text{ チャート2} \end{array}$$

- 位相空間 M のアトラス; 位相空間 M を覆いつくすチャートの集合,
- 位相空間 M のチャート; M 上の開集合 U から \mathbb{R}^d 上の開集合 V への同相写像 $\phi: U \rightarrow V$ があって、 (U, ϕ) を M のチャートという。

定理6 (特異点解消定理のバイズー一般理論向け版)

$K(w)$: 開集合 $W \subset \mathbb{R}^d$ 上の非負値をとる解析関数,
 $K(w) = 0$ を満たす $w \in W$ が存在するとする。

このような任意の $K(w)$ に対し、ある d 次元多様体 M と M 上の局所座標から W への解析写像 g が存在して M の局所座標系ごとに式(4.1), (4.2) が成立するようにできる。

但し $k = (k_1, k_2, \dots, k_d)$, $h = (h_1, h_2, \dots, h_d)$ は非負整数の集合であり、局所座標系ごとに異なる。 (k_1, k_2, \dots, k_d) のうち少なくとも一つは0でない。


$$K(g(u)) = u_1^{2k_1} u_2^{2k_2} \dots u_d^{2k_d} = u^{2k} \quad (4.1)$$

$$|g'(u)| = b(u) |u_1^{h_1} u_2^{h_2} \dots u_d^{h_d}| = b(u) |u^h| \quad (4.2)$$

但し $|g'(u)|$ は g のヤコビアン(ヤコビ行列の行列式)の絶対値で、 $b(u)$ は正の値をとる解析関数(おそらく、局所座標系ごとに異なる)。

例14. 例14をやる前に、例13で多様体を定義して11るのでそれを見る。

x, y 平面の上の各点に、新しい座標 (u, w) と (s, t) を割りあてるとする。




新しい座標 (u, w) は、
 u はその点の x 座標と同じ。
 w はその点の y 座標を
その点の x 座標で割ったもの。

(x, y 平面上に (u, w) の格子を
かくと上図のようになる。

しかし、 x, y 平面上の y 軸上

(原点除く)には (u, w) を割りあてられない。



新しい座標 (s, t) は、
 t はその点の y 座標と同じ。
 s はその点の x 座標を
その点の y 座標で割ったもの。

(x, y 平面上に (s, t) の格子を
かくと上図のようになる。

しかし、 x, y 平面上の x 軸上

(原点除く)には (s, t) を割りあてられない。

$\{(u, w)\}$ は y 軸上(原点除く)を覆わないし、
 $\{(s, t)\}$ は x 軸上(原点除く)を覆わないので、
 $\{(u, w)\}$ と $\{(s, t)\}$ はそれぞれ単独では \mathbb{R}^2 のアトラスにならないが、
これらを組み合わせれば \mathbb{R}^2 を覆い尽くすので \mathbb{R}^2 のアトラスになる。
 \mathbb{R}^2 にこのようなアトラスを割りあてた多様体を M とする(これが例13の多様体)。

いま \mathbb{R}^2 上の関数 $K(x, y) = x^2 + y^2$ を考える。

この関数は $K(x, y) = f_x(x) f_y(y)$ の形をしていない。
座標を取りかえてこのような因数分解ができるようにしたい。

そこで、先の多様体 M 上の局所座標から \mathbb{R}^2 への写像 g_0, g_1

$$(x, y) = g_0(u, w) = (u, uw)$$

$$(x, y) = g_1(s, t) = (st, t)$$

を考えると、以下のように因数分解できる(ただし定理6の形とはちがう)。

$$K(g_0(u, w)) = u^2 + u^2 w^2 = u^2(1 + w^2)$$

$$K(g_1(s, t)) = s^2 t^2 + t^2 = t^2(s^2 + 1)$$

また、 $|g_0'(u, w)| = \left| \det \begin{pmatrix} 1 & w \\ 0 & u \end{pmatrix} \right| = |u|$ より、 g_0, g_1 のヤコビアンも
因数分解できている。

$$|g_1'(s, t)| = \left| \det \begin{pmatrix} t & 0 \\ s & 1 \end{pmatrix} \right| = |t|$$

定理6の形と合うようにやり直す。写像 g_0, g_1 を、

$$(x, y) = g_0(u, w) = \left(\frac{u}{\sqrt{1+w^2}}, \frac{uw}{\sqrt{1+w^2}} \right)$$

$$(x, y) = g_1(s, t) = \left(\frac{st}{\sqrt{1+s^2}}, \frac{t}{\sqrt{1+s^2}} \right)$$

とすると、

$$K(g_0(u, w)) = \left(\frac{u}{\sqrt{1+w^2}} \right)^2 + \left(\frac{uw}{\sqrt{1+w^2}} \right)^2 = u^2$$

$$K(g_1(s, t)) = \left(\frac{st}{\sqrt{1+s^2}} \right)^2 + \left(\frac{t}{\sqrt{1+s^2}} \right)^2 = t^2$$

$$|g_0'(u, w)| = \left| \det \begin{pmatrix} (1+w^2)^{-\frac{1}{2}} & w(1+w^2)^{-\frac{1}{2}} \\ -uw(1+w^2)^{-\frac{3}{2}} & u(1+w^2)^{-\frac{1}{2}} - u w^3 (1+w^2)^{-\frac{3}{2}} \end{pmatrix} \right| = \frac{1}{1+w^2} |u|$$

$$|g_1'(s, t)| = \left| \det \begin{pmatrix} t(1+s^2)^{-\frac{1}{2}} & s t^2 (1+s^2)^{-\frac{3}{2}} \\ s(1+s^2)^{-\frac{1}{2}} & (1+s^2)^{-\frac{1}{2}} \end{pmatrix} \right| = \frac{1}{1+s^2} |t|$$

$$\begin{aligned} k^{(0)} &= (1, 0) \\ k^{(1)} &= (0, 1) \\ h^{(0)} &= (1, 0) \\ h^{(1)} &= (0, 1) \\ b^{(0)}(u) &= \frac{1}{1+u^2} \\ b^{(1)}(u) &= \frac{1}{1+u^2} \end{aligned}$$


定理6の
形と合う!

定義域の各点においてその点の周りのテイラー展開と一致

\mathbb{R}^d の開集合であって、じゅうぶん大きな半径 $r > 0$ の球で覆うことができる。

☆ 注意 34

- 本書ではパラメータ集合 W は \mathbb{R}^d のコンパクトな部分集合であり、かつ、開集合 $W' \supset W$ が存在して平均誤差 $K(w)$ は W' 上の解析関数であると仮定する(ので定理 6 がつかえる)。
- 定理 6 を満たす g はコンパクト集合への引き戻しがコンパクトである。すなわち、 $C \subset W'$ がコンパクトであれば $g^{-1}(C) = \{u \mid g(u) \in C\}$ もコンパクトである。よって $g^{-1}(W)$ もコンパクトである。



位相空間の部分集合がコンパクト；任意の開被覆が有限部分開被覆をもつ。

※ 以降、 M とかいたら $g^{-1}(W)$ を指す。

※ 1 の分割 (後述) が存在するためにはコンパクトが要る。

☆ 注意 36

- ところで、事後分布は $p(w | X^n) \propto \exp(-n\beta K_n(w)) \varphi(w)$ だった。これを W 上の分布から M 上の分布にすると、以下となる(※ 仮に、チャート 1 枚で覆われているとする)。

$$\exp(-n\beta K_n(g(u))) \varphi(g(u)) |g'(u)|$$

定理 6 から $K(g(u))$ は標準形 u^{2k} になる。それに近づく。

定理 6 から $\varphi(g(u))$ は標準形 $b(u) |u^h|$ になる。 $b(u)$ は正の値をとる解析関数。

確率変数の変換 $u = g^{-1}(w)$ のとき、 $p_u(u) = |g'(u)| p_w(g(u))$

$\varphi(g(u))$ をどうすればいいのか。

- ① $\varphi(w)$ が $w \in W$ でゼロとならないとき、

$\varphi(g(u))$ は $b(u)$ に含めてしまえばよい。

定理 8 のため

(但し、 $b(u)$ は無限回微分できないといけなないので、そういう都合のよい $\varphi(w)$ をつかうことにする。

- ② $\varphi(w)$ が $w \in W$ でゼロとなるとき、 $\varphi(w) = \varphi_1(w) \varphi_2(w)$

として、 $\varphi_2(w)$ は $b(u)$ に含めてしまう。

(但し、 $b(u)$ は無限回微分...))

ゼロに なる 解析関数。 都合がいい。

そういう都合のいい $\varphi(w)$ をつかう。

$\varphi_i(w)$ が解析関数ならば

$\varphi_i(w)$ については、 $K(w)$ に定理 6 を適用するとき $\varphi_i(g(w)) = |u^h|$ となるように g を選ぶことができる。

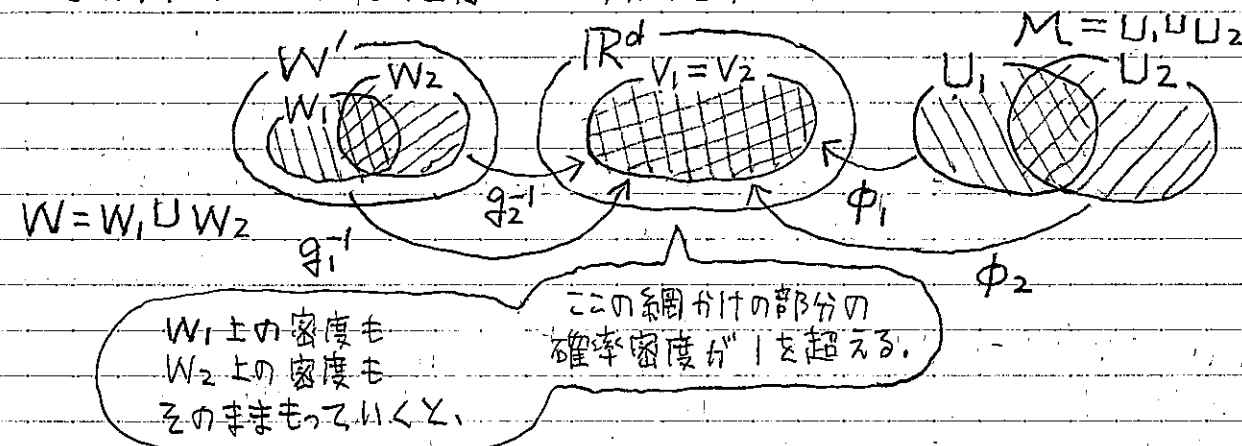
(「 $K(w)$ と $\varphi_i(w)$ は同時特異点解消が可能である。」)

なので結局事後分布は $\exp(-n\beta K_n(g(u))) b(u) |u^h|$ の形になる。

($b(u)$ は正の値をとる無限回微分できる関数。)

☆ 注意 37 (定義 15)

- しかし、 M はチャート 1 枚で覆われているとは限らない。どのチャートについても注意 36 の考え方をすると、確率密度がくるってくる。



そこで、 M がコンパクトなとき「1 の分割」ができることを利用する。

つまり、 M がコンパクトなとき、 M 上の任意の点 p に対して

$f_1(p) + f_2(p) = 1$ であり、かつ、 $f_1(p) \geq 0$, $f_2(p) \geq 0$ であり

$f_1(p)$ は U_1 の外では 0, $f_2(p)$ は U_2 の外では 0 となるような

写像 f_1, f_2 が存在する (U_1 と U_2 が重なる部分では「1 を分け合う」)。

実際には、1 を分け合うのではなく、事前分布 $\varphi(w)$ を分け合う。

$\varphi(w) = \sum \varphi_\alpha(w)$ のように各チャートが担当する確率密度を分けて

おけば、確率密度がくるくるとはならない。

- また、上図でいう V_1, V_2 は \mathbb{R}^d の部分集合としてどんな形なのか気になるが、(M がコンパクトなので) 適宜チャートの覆い方を細分化すれば各 V_α は $[0, 1]^d$ (超立方体) の形をしていて一般性を失わない。

これから実際に定理6を用いて事後分布を標準形にしていこう。

まず平均誤差 $K(w)$ に定理6を適用すると以下となる。

$$K(q(u)) = u^{2k}$$

また、この章では相対的に有限な分散を仮定しているのので、任意の w で

$$\mathbb{E}_x[f(x, w)] \geq c_1 \mathbb{E}_x[f(x, w)^2] \quad (c_1 > 0 \text{ は定数})$$

$$\Leftrightarrow u^{2k} \geq c_1 \int q(x) f(x, q(u))^2 dx$$

なので、この右辺は u^{2k} で割り切れる。

$\Rightarrow f(x, q(u))^2$ は u^{2k} で割り切れる。

$\Rightarrow f(x, q(u))$ は u^k で割り切れる。

補題 20

対数尤度比 $f(x, q(u))$ が u の解析関数であるとする。
このとき、ある解析関数 $a(x, u)$ が存在して、以下が成り立つ。
 $f(x, q(u)) = u^k a(x, u)$

⊙ もし成り立たないとする $f(x, q(u)) = u^k a(x, u) + b(x, u)$
(但し $b(x, u)$ は u^k で割り切れない、常にゼロでもない) とするが、
そうすると、以下が成り立たなければならない (任意の u で)。

$$u^{2k} \geq c_1 \int q(x) (u^k a(x, u) + b(x, u))^2 dx$$

$$1 \geq c_1 \int q(x) \left(a(x, u)^2 + \frac{2}{u^k} a(x, u) b(x, u) + \frac{b(x, u)^2}{u^{2k}} \right) dx$$

ここで、 $K(w_0) = 0$ より、 $q(u_0) = w_0$ とする u_0 では、

$$K(q(u_0)) = u_0^{2k} = 0 \Rightarrow u_0^k = 0 \text{ である。}$$

この u_0 では $\left| \frac{b(x, u_0)}{u_0^k} \right|$ は正の無限大になってしまう。これは c_1 が正の定数であることに反する。

$$\left. \begin{aligned} f(x, q(u)) &= u^k a(x, u) \\ K(q(u)) &= \int f(x, q(u))^2 q(x) dx \end{aligned} \right\} u^k = \int a(x, u)^2 q(x) dx$$

u を添字とした

$\xi_n(u)$ を以下のように定義する (サンプルの選び方に依存する確率過程)。

$$\xi_n(u) \equiv \frac{1}{\sqrt{n}} \sum_{i=1}^n (u^k - a(x_i, u)) = \sqrt{n} u^k - \frac{1}{\sqrt{n}} \sum_{i=1}^n a(x_i, u)$$

$$\mathbb{E}[\xi_n(u)] = \sqrt{n} u^k - \frac{1}{\sqrt{n}} \mathbb{E} \left[\sum_{i=1}^n a(x_i, u) \right]$$

$$= \sqrt{n} u^k - \frac{1}{\sqrt{n}} \int \left(\sum_{i=1}^n a(x_i, u) \right) q(x_1) \cdots q(x_n) dx_1 \cdots dx_n$$

$$= \sqrt{n} u^k - \frac{1}{\sqrt{n}} n u^k = 0$$

$$\mathbb{E}[\xi_n(u) \xi_n(v)] = \mathbb{E} \left[\left(\sqrt{n} u^k - \frac{1}{\sqrt{n}} \sum_{i=1}^n a(x_i, u) \right) \left(\sqrt{n} v^k - \frac{1}{\sqrt{n}} \sum_{j=1}^n a(x_j, v) \right) \right]$$

$$= n u^k v^k - n u^k v^k - n u^k v^k + \frac{1}{n} \mathbb{E} \left[\left(\sum_{i=1}^n a(x_i, u) \right) \left(\sum_{j=1}^n a(x_j, v) \right) \right]$$

$$= -n u^k v^k + \frac{1}{n} \int \left(\sum_{i=1}^n \sum_{j=1}^n a(x_i, u) a(x_j, v) \right) q(x_1) \cdots dx_1 \cdots$$

$$= -n u^k v^k + \frac{1}{n} \cdot n \int a(x, u) a(x, v) q(x) dx$$

$$+ \frac{1}{n} (n^2 - n) \left(\int a(x, u) q(x) dx \right) \left(\int a(x, v) q(x) dx \right)$$

$$= -n u^k v^k + \mathbb{E}_x[a(x, u) a(x, v)] + (n-1) u^k v^k$$

$$= \mathbb{E}_x[a(x, u) a(x, v)] - u^k v^k$$

なので、確率過程 $\xi_n(u)$ は平均 0、自己共分散 $\mathbb{E}_x[a(x, u) a(x, v)] - u^k v^k$ 。

また、 $\xi_n(u)$ は n を大きくしたとき、同じ平均と自己共分散をもつ

ガウス過程に法則収束する (\because 8.5.3 の (2))。

これを $\xi(u)$ とかく。

$\xi(u)$ に関する平均を $\mathbb{E}_\xi[\cdot]$ とかく。

補題 2

真の分布が確率モデルで実現可能な場合は、 $K(q(u)) = 0$ なる u で
 $\mathbb{E}[\xi_n(u)^2] = \mathbb{E}_\xi[\xi(u)^2] = \mathbb{E}_X[a(X, u)^2] = 2$ である。

$$\textcircled{\text{∴}} \mathbb{E}[\xi_n(u)^2] = \mathbb{E}_X[a(X, u)^2] = u^{2k} = \mathbb{E}[a(X, u)^2]$$

$$\mathbb{E}_\xi[\xi(u)^2] = \mathbb{E}_X[a(X, u)^2] = u^{2k} = \mathbb{E}[a(X, u)^2]$$

$$\begin{aligned} \mathbb{E}_X[a(X, u)^2] &= \int a(X, u)^2 q(X) dX \\ &= \frac{1}{u^{2k}} \int f(X, q(u))^2 q(X) dX \end{aligned}$$

補題 4, 5 の帰結より、ここが $K(q(u))$ なる u
 に近づくと $2u^{2k}$ に近づくと。

定理 7

経験誤差は $nK_n(q(u)) = nu^{2k} - \sqrt{n}u^k \xi_n(u)$ 。

事前分布は $|u^h| b(u)$ 。

$\xi_n(u)$ は n を大きくすると $\xi(u)$ に法束収束する。

$$\begin{aligned} nK_n(q(u)) &= \sum_{i=1}^n f(x_i, q(u)) = \sum_{i=1}^n u^k a(x_i, u) \\ &= u^k (nu^k - \sqrt{n} \xi_n(u)). \end{aligned}$$

$$p(w|X^n) \propto \exp(-n\beta K_n(w)) \varphi(w)$$

は、 M の世界では以下のようなになる。

$$p(u|X^n) \propto \exp(-n\beta u^{2k} + \sqrt{n}\beta u^k \xi_n(u)) |u^h| b(u)$$

ここは n が大きくなると事後分布
 がたがっていきそうなイメージ。

後の都合により、 u^{2k} の密度を考えていきたい。

・デルタ関数 — 必お他の関数との積分の形で用いて、 $x=0$ の値を
 抜き出すもの。
 $\int \delta(x) \varphi(x) dx = \varphi(0)$

$$\int \delta(-x) \varphi(x) dx = \int \delta(x') \varphi(-x') dx' = \varphi(0) \text{ より、}$$

$$\int [\delta(x) - \delta(-x)] \varphi(x) dx = 0 \text{ なるので } \delta(x) - \delta(-x) = 0$$

$$\int \delta(t-x) \varphi(x) dx = \int \delta(x') \varphi(t-x') dx' = \varphi(t)$$

$$\int \delta(ax) \varphi(x) dx = \begin{cases} \int \delta(x') \varphi(\frac{x}{a}) \frac{dx'}{a} = \frac{1}{a} \varphi(0) & (a > 0) \\ -\int \delta(x') \varphi(\frac{x}{a}) \frac{dx'}{a} = -\frac{1}{a} \varphi(0) & (a < 0) \end{cases}$$

$$\begin{aligned} \textcircled{\text{H}}(x) &= \begin{cases} 1 & (x \geq 0) \\ 0 & (x < 0) \end{cases} \text{ と定義すると } \int \textcircled{\text{H}}(t-x) \varphi(x) dx = \int_{-\infty}^t \varphi(x) dx \\ \text{なるので } \frac{d}{dt} \int \textcircled{\text{H}}(t-x) \varphi(x) dx &= \varphi(t) \text{ より、 } \frac{d}{dt} \textcircled{\text{H}}(t-x) = \delta(t-x) \end{aligned}$$

$$\int \textcircled{\text{H}}(t-x^2-y^2-z^2) \varphi(x, y, z) dx dy dz = \int_{x^2+y^2+z^2 < t} \varphi(x, y, z) dx dy dz$$

$$\text{なるので、} \int \delta(t-x^2-y^2-z^2) \varphi(x, y, z) dx dy dz = \frac{d}{dt} \left(\int_{x^2+y^2+z^2 < t} \varphi(x, y, z) dx dy dz \right)$$

・特に $t \rightarrow +0$ のとき、原点の近傍で

$$\varphi(x, y, z) = \varphi(0) + O(\sqrt{x^2+y^2+z^2}) \text{ なるので、}$$

$$\textcircled{*} = \frac{d}{dt} \left(\varphi(0) \frac{4\pi}{3} t^{3/2} + O(\sqrt{t}) \frac{4\pi}{3} t^{3/2} \right) = 2\pi \varphi(0) \sqrt{t} + O(t)$$

となることから $t \rightarrow 0$ での $\delta(t-x^2-y^2-z^2)$ は以下に近づく。

$$2\pi \delta(x) \delta(y) \delta(z) \sqrt{t} + O(\sqrt{t})$$

定義 17

多重指数 $k=(k_j)$, $h=(h_j)$ から定まる以下の値を考える。

$$\left(\frac{h_j+1}{2k_j}\right) \quad (j=1, \dots, d) \quad k_j=0 \text{ のときは } +\infty \text{ とおくことにする。}$$

これらの最小値を λ , 最小値をとる j の個数を m とするとき λ のことを k, h から定まる実数関数値, m をその多重度とよぶ。

例. $k=(2, 3, 4)$, $h=(1, 2, 6)$ なら

$$\left(\frac{h_j+1}{2k_j}\right) = \left(\frac{1+1}{4}, \frac{2+1}{6}, \frac{6+1}{8}\right) = \left(\frac{1}{2}, \frac{1}{2}, \frac{7}{8}\right)$$

なので $\lambda = \frac{1}{2}$, $m=2$ である。

以降, 座標 u の成分を並べかえて, 上の最小値をとる j を最小に集め, そうでない j を後ろにまわし, $u=(u_a, u_b)$ とかく。

×リソ変換と×リソ逆変換を以下のように定義する。

$$f(t) \xrightleftharpoons[\text{×リソ逆変換}]{\text{×リソ変換}} F(z) \quad (z \in \mathbb{C})$$

$$F(z) = (Mf)(z) = \int_0^\infty t^z f(t) dt \quad \left(\begin{array}{l} t^z = e^{z \log t} \\ = e^{a \log t} (\cos b + i \sin b)^{\log t} \end{array} \right)$$

$$f(t) = (M^{-1}F)(t) = \frac{1}{2\pi i} \int_{c-i\infty}^{c+i\infty} F(z) t^{-z} dz \quad \left(\begin{array}{l} \text{但し複素平面上的} \\ \text{縦軸に沿って積分} \end{array} \right)$$

一般に $F(z)$ は $a < \operatorname{Re}(z) < b$ で解析関数となるような定数 a, b をとつ (ので, 逆変換の定数 c は $a < c < b$ であるものとする)。

×リソ変換は, 次の①②が等価であるという性質をもつ。

$$\textcircled{1} \quad t \rightarrow 0 \text{ のとき } f(t) \cong t^{\lambda-1} (-\log t)^{m-1}$$

$$\textcircled{2} \quad (Mf)(z) \cong \frac{1}{(z+\lambda)^m}$$

補題 22

$\lambda > 0$ を実数, $m > 0$ を自然数とする。

$$f_m(t) = \begin{cases} t^{\lambda-1} (-\log t)^{m-1} & (0 < t < 1) \\ 0 & (それ以下) \end{cases} \quad \text{の×リソ変換は}$$

$$(Mf_m)(z) = \frac{(m-1)!}{(z+\lambda)^m} \quad \text{である。}$$

$$\begin{aligned} \therefore (Mf_m)(z) &= \int_0^1 t^z t^{\lambda-1} (-\log t)^{m-1} dt \\ &= \left[\frac{t^{z+\lambda}}{z+\lambda} (-\log t)^{m-1} \right]_0^1 + \frac{m-1}{z+\lambda} \int_0^1 t^{z+\lambda} \frac{(-\log t)^{m-2}}{t} dt \\ &= \frac{(m-1)}{z+\lambda} (Mf_{m-1})(z) \\ &= \frac{(m-1)(m-2)}{(z+\lambda)(z+\lambda)} (Mf_{m-2})(z) \quad \text{のようにどんどん} \\ &\quad m \text{ を減らせる。} \end{aligned}$$

$$(Mf_1)(z) = \int_0^1 t^{z+\lambda-1} dt = \frac{1}{(z+\lambda)} \quad \text{なので、}$$

$$(Mf_m)(z) = \frac{(m-1)}{(z+\lambda)} \cdot \frac{(m-2)}{(z+\lambda)} \cdots \frac{2}{(z+\lambda)} \cdot \frac{1}{(z+\lambda)} \cdot \frac{1}{(z+\lambda)} \quad \square$$